



BLM0467 Doğal Dil İşlemeye Giriş

TÜRKÇE MORFOLOJİK ÇÖZÜMLEME VE UPOS ETİKETLEME

DÖNEM PROJESİ DETAYLI RAPORU

istatistiksel makine öğrenmesi: multinomial logistic regression

github linki: <https://github.com/suhailkhaleqi/Turkish-Morphological-Disambiguation>

video linki : <https://youtu.be/4nwQ8pyHV-k?si=laB2bLilvNhOfPFn>

Üye (Adı Soyadı / No)	Görev Alanı	Proje ve Kod Katkısı
Edem Makhsudov 22360859373	Veri Önleme & BIO Formatlama	CoNLL-U veri okuyucu (parse_conllu), BIO etiketleme ve çıkı yönetimi.
Suhail Khaleqi 22360859401	Özellik Mühendisliği (Feature)	Kök/ek analizi (get_suffix_features), dilbilgisel ipuçları ve bağlam tasarımı.
Magomed Umkhanov 22360859374	ML Model & Görsel Değerlendirme	Lojistik Regresyon model eğitimi, başarı metriklerinin hesabı ve grafik çizimleri.

1. GİRİŞ VE PROBLEM TANIMI

Doğal Dil İşleme (DDİ / NLP) süreçlerinde en temel adımlardan biri, sözcüklerin cümle içindeki görevlerini belirlemektir. Bu işlem Sözcük Türü Etiketleme (POS Tagging) ve ardından gelen Morfolojik Çözümleme (Morphological Disambiguation) aşamalarından oluşur. Türkçe gibi sondan eklemeli (agglutinative) ve zengin morfolojik yapıya sahip dillerde bu görev oldukça zordur. Türkçe kelimeler, köklerine gelen yapım ve çekim ekleri vasıtasıyla çok sayıda farklı morfolojik analiz ve sözcük türü edinebilirler.

Örneğin, Türkçe’de sıkça kullanılan "yaz" kelimesi ele alındığında:

"Bu yaz tatile gideceğiz." cümlesinde bir isim (NOUN - mevsim anlamında),

"Defterine güzel bir şiir yaz." cümlesinde ise bir fiil (VERB - yazmak fiili emir kipi) görevindedir.

Benzer şekilde "yalnız" kelimesi cümledeki bağlamına göre isim (NOUN), sıfat (ADJ), zarf (ADV), bağlaç (CCONJ) veya edat (ADP) olabilmektedir.

Bu belirsizliklerin (ambiguity) çözülmesi, sözcüklerin tek başına değil, içinde bulundukları cümlelerin sağ ve sol bağlamı (context) ile birlikte ele alınmasını gerektirir. Bu projenin amacı; istatistiksel bir makine öğrenmesi modeli (Multinomial Logistic Regression) ve zengin özellik mühendisliği (Feature Engineering) yöntemleri kullanarak Türkçe kelimelere en uygun Evrensel Sözcük Türü (UPOS - Universal Part of Speech) etiketlerini atayan yüksek başarılı bir morfolojik çözümleyici geliştirmektir.

2. VERİ KÜMESİ VE STANDARTLAR

2.1. Turkish BOUN UD Treebank

Projede eğitim ve değerlendirme süreçleri için Boğaziçi Üniversitesi tarafından derlenen ve uluslararası Universal Dependencies (UD) standartlarına uygun olan Turkish BOUN UD Treebank veri kümesi kullanılmıştır. Veri seti, farklı türlerdeki metinlerden elde edilmiş zengin bir kelime dağarcığına sahiptir.

2.2. Veri Kümesi İstatistikleri

Modelin eğitildiği ve test edildiği veri kümesinin sayısal dağılımı aşağıdaki gibidir:

Eğitim Seti Cümle Sayısı: 9.761 cümle

Eğitim Seti Token Sayısı: 100.713 kelime/noktalama

Test Seti Cümle Sayısı: Yaklaşık 1.200 cümle

Test Seti Token Sayısı: 12.210 kelime/noktalama

Sınıf Sayısı (UPOS Sınıfları): 15 farklı kategori

2.3. CoNLL-U Formatı ve UPOS Etiketleri

Kullanılan veriler standart CoNLL-U formatındadır. Bu formatta her satır bir sözcüğü (token) temsil eder ve sekme karakteriyle (tab) ayrılmış 10 sütundan oluşur:

ID: Cümle içindeki kelime indeksi (1-indexed).

FORM: Kelimenin cümledeki ham hali.

LEMMA: Kelimenin sözlük kökü (lemma).

UPOS: Evrensel sözcük türü etiketi (hedef değişken).

XPOS: Dile özgü detaylı POS etiketi.

FEATS: Morfolojik özellikler (Örn: Case=Nom, Number=Sing vb.).

HEAD: Bağımlılık ilişkisi kurduğu kelimenin ID'si.

DEPREL: Bağımlılık ilişkisinin türü.

DEPS: Gelişmiş bağımlılık grafiği.

MISC: Ek bilgiler (Boşluk durumu, model tahmin etiketleri vb.).

Projede modelin sınıflandırma yaptığı 15 UPOS etiketi şunlardır: NOUN (İsim), VERB (Fiil), ADJ (Sıfat), ADV (Zarf), PROPN (Özel İsim), PUNCT (Noktalama İşareti), NUM (Sayı), PRON (Zamir), DET (Belirteç), AUX (Yardımcı Fiil), CCONJ (Bağlaç), ADP (Edat/İlgeç), PART (Parçacık), SCONJ (Yan Cümle Bağlacı), INTJ (Ünlem).

3. YÖNTEM VE MODEL MİMARİSİ

Proje kapsamında geliştirilen sistemin uçtan uca akışı (pipeline) ve kullanılan yöntemler şu şekildedir:

3.1. Pipeline (İşlem Akışı)

Geliştirilen sistem ardışık 6 temel aşamadan oluşmaktadır:

CoNLL-U Veri Okuma: Eğitim ve test setleri dosyadan taranarak çoklu kelime yapıları (multi-word tokens) elenip temizlenir ve cümle nesneleri oluşturulur.

Zengin Özellik Çıkarımı: Her bir kelime için morfolojik, ek tabanlı ve bağlamsal özellikler hesaplanır.

Vektörleştirme (DictVectorizer): Kategorik ve metinsel özellik sözlükleri, modelin işleyebileceği seyrek (sparse) öznitelik matrisine dönüştürülür.

Model Eğitimi: Seyrek matris üzerinde Çok Sınıflı Lojistik Regresyon (Multinomial Logistic Regression) eğitilir.

Tahmin (Inference): Test veri kümesindeki kelimeler üzerinde UPOS tahmini gerçekleştirilir.

Değerlendirme ve Görselleştirme: Tahmin sonuçları üzerinden başarı metrikleri hesaplanır, grafikler üretilir ve tahminler BIO şemasıyla standart CoNLL-U çıktısı olarak kaydedilir.

3.2. Özellik Mühendisliği (Feature Engineering)

Türkçe gibi sondan eklemeli dillerde kelimenin sadece kendisi sınıflandırma için yeterli bilgi sunmaz. Kelimenin aldığı ekler ve cümlenin yapısı POS etiketini doğrudan belirler. Bu nedenle modelde üç grupta toplanan zengin özellikler tanımlanmıştır:

A. Ek ve Kök Özellikleri (Suffix & Prefix Features)

Karakter Bazlı Son Ekler (suffix_1 - suffix_5): Kelimelerin son 1, 2, 3, 4 ve 5 harfi çıkarılmıştır. Bu özellik, Türkçe'deki yapım ve çekim eklerini (Örn: "-lar", "-da", "-lık", "-ma") yakalayarak kelime türünün tespit edilmesinde en kritik katkıyı sağlamaktadır.

Ön Ekler (prefix_1 - prefix_3): Kelimelerin ilk 1, 2 ve 3 harfi kök hakkında temel bir ipucu vermesi adına modelde yer almıştır.

B. Morfolojik İpucu ve Yapısal Özellikler

Zaman Eki Kontrolleri: Kelimenin şimdiki zaman eki barındırıp barındırmadığı (has_progressive - > -iyor), öğrenilen geçmiş zaman eki (has_past_nfh -> -miş) veya görülen geçmiş zaman eki (has_past_fh -> -di/-ti) taşıyıp taşımadığı kontrol edilmiştir. Bu özellikler VERB etiketlemesi için yüksek ayırt ediciliğe sahiptir.

İsim Yapım Eki Kontrolü (has_lik_suffix): Sözcüğün sonunun -lık/-lik/-luk/-lük ekleriyle bitip bitmediği kontrol edilerek NOUN veya ADJ sınıfına geçiş olasılıkları beslenmiştir.

Yazım Kuralları ve Karakter Analizleri: Kelimenin büyük harfle başlayıp başlamadığı (is_upper_start), kesme işareti içerip içermediği (has_apostrophe), tamamen sayılardan oluşup oluşmadığı (is_digit) veya içinde sayı geçip geçmediği (has_digit) ile noktalama işareti olup olmadığı (is_punct) özellik olarak eklenmiştir.

C. Bağlam (Context) Özellikleri

Kelimelerin belirsizliğini gidermek amacıyla kayan pencere (sliding window) yöntemiyle sağ ve sol bağlam bilgileri öznitelik matrisine dahil edilmiştir:

Sol Bağlam: Bir önceki kelimenin kendisi (prev1_form), son iki harfi (prev1_suffix2), UPOS etiketi (prev1_upos) ve iki önceki kelimenin aynı bağlamsal bilgileri (prev2_form, prev2_upos).

Sağ Bağlam: Bir sonraki kelimenin kendisi (next1_form), ilk iki harfi (next1_prefix2), UPOS etiketi (next1_upos) ve iki sonraki kelimenin aynı bağlamsal bilgileri (next2_form, next2_upos).

Cümle İçi Konum: Kelimenin cümle içindeki bağıl sırası kategorize edilerek (position_ratio_cat) cümlelerin başında, ortasında veya sonunda bulunma durumu modele yansıtılmıştır.

3.3. Sınıflandırma Modeli: Multinomial Logistic Regression

Projede istatistiksel makine öğrenmesi modeli olarak Multinomial Logistic Regression (Çok Sınıflı Lojistik Regresyon) algoritması tercih edilmiştir. Modelin hiper-parametreleri ve mimari detayları şu şekildedir:

Çözücü (Solver): saga (Sparse/seyrek özellik matrisleri ve çok sınıflı büyük veri kümeleri üzerinde hızlı yakınsayan Stochastic Average Gradient Descent algoritması tercih edilmiştir).

Maksimum İterasyon Sayısı (max_iter): 200 (Modelin kararlı bir şekilde yakınsaması hedeflenmiştir).

Düzenleştirme Katsayısı (C): 1.0 (L2 düzenleştirmesi kullanılarak modelin aşırı öğrenmesi - overfitting- engellenmiştir).

Paralel İşlem (n_jobs): -1 (Eğitim sürecini hızlandırmak için işlemcinin tüm çekirdekleri paralel çalıştırılmıştır).

Süre ve Veri Hacmi İstatistikleri:

Eğitim Süresi: 12.9 saniye

Toplam Pipeline Çalışma Süresi: 34.7 saniye


İşlenen Toplam Eğitim Tokeni: 100.713 token

4. DENEYSEL SONUÇLAR VE DEĞERLENDİRME

Modelin performansı test seti üzerindeki 12.210 token referans alınarak ölçülmüştür. Test seti sonuçlarına göre hesaplanan genel başarı oranları şu şekildedir:

Doğruluk Oranı (Accuracy): %92.23
Ağırlıklı F1-Skor (Weighted F1): %92.16
Makro Hassasiyet (Macro Precision): %87.80
Makro Duyarlılık (Macro Recall): %83.32
Makro F1-Skor (Macro F1): %84.82

Ağırlıklı F1-Skor değerinin (%92.16), Makro F1-Skor değerinden (%84.82) belirgin şekilde yüksek olması; modelin veri kümesinde çok sık rastlanan ana sınıflarda (NOUN, VERB, PUNCT) mükemmel yakın bir başarıyı sergilediğini, veri kümesinde az temsil edilen bazı azınlık sınıflarında ise performansın göreceli olarak daha düşük olduğunu göstermektedir.





Genel Başarı Metrikleri ve Doğru/Yanlış Tahmin Pasta Grafiği

4.1. Sınıf Bazlı Detaylı Performans Sonuçları

Modelin 15 farklı UPOS etiket sınıfı üzerindeki hassasiyet, duyarlılık ve F1-Skor dağılımı aşağıdaki tabloda F1-Skoruna göre azalan sırada sunulmuştur:

UPOS Sınıfı Precision (Hassasiyet) Recall (Duyarlılık) F1-Score Destek (Support)
Performans Değerlendirmesi

PUNCT	1.0000	1.0000	1.0000	2.028	Mükemmel
DET	0.9574	0.9872	0.9720	546	Çok İyi
CCONJ	0.9459	0.9347	0.9403	337	Çok İyi
VERB	0.9525	0.9213	0.9367	2.199	Çok İyi
PRON	0.9290	0.9085	0.9187	317	Çok İyi
NOUN	0.9000	0.9353	0.9173	3.955	Çok İyi
NUM	0.9134	0.9167	0.9150	276	Çok İyi
ADP	0.9609	0.8371	0.8947	264	İyi
PART	0.8298	0.9630	0.8914	162	İyi
AUX	0.8675	0.9000	0.8834	240	İyi
PROPN	0.8565	0.8730	0.8647	677	İyi
ADV	0.8455	0.7979	0.8210	480	İyi / Orta
ADJ	0.8448	0.7753	0.8086	681	İyi / Orta
SCONJ	0.8333	0.3846	0.5263	26	Orta / Zayıf
INTJ	0.5333	0.3636	0.4324	22	Zayıf
ORTALAMA	0.8780	0.8332	0.8482	12.210	Çok Başarılı



Sınıf Bazlı Detaylı Başarı Dağılımı ve Sınıf Dağılım Grafiği


4.2. Hata Analizi ve Karışıklık Matrisi (Confusion Matrix) Değerlendirmesi

Modelin sınıflar arası geçişlerini ve yaptığı hataları analiz etmek üzere üretilen Karışıklık Matrisi incelendiğinde şu sonuçlara ulaşılmaktadır:

Mükemmel Sınıflar: Noktalama işaretleri (PUNCT) sıfır hata ile (%100) tahmin edilmiştir. Bu durum, `is_punct` özelliğinin ayırt edici gücünden kaynaklanmaktadır.

Sıfat-İsim Karışıklığı (ADJ ↔ NOUN): En belirgin hata örüntüsü sıfatlar ile isimler arasında yaşanmıştır. Türkçe morfolojisinde sıfatlar cümle içinde doğrudan isimleşebilir (adlaşmış sıfat). Örneğin "genç insanlar" ifadesinde sıfat olan "genç" kelimesi, "gençler" şeklinde tek başına

Azınlık Sınıfların Durumu (SCONJ ve INTJ): Yan cümle bağlaçları (SCONJ - 26 örnek) ve ünlemler (INTJ - 22 örnek) veri setinde çok kısıtlı sayıda yer almaktadır. Bu sınıflarda duyarlılık değerinin (Recall) düşük kalması, modelin bu etiketleri yeterince öğrenememesinden ve daha baskın olan zarf (ADV) veya isim (NOUN) sınıflarına yönelmesinden kaynaklanmaktadır.



5. CoNLL-U B/I İŞARETLEME VE TAHMİN FORMATI

Dönem projesinin 2. isterini karşılamak amacıyla test setindeki tüm tahminler BIO etiketleme şemasına (B-[UPOS] ve I-[UPOS]) uygun şekilde biçimlendirilmiş ve standart CoNLL-U formatında kaydedilmiştir.

5.1. BIO İşaretleme Mantığı

B-[UPOS] (Beginning): Bir kelimenin cümle içindeki sözcük türü etiketinin başlangıcını temsil eder. Bir önceki kelimenin etiketiyle o anki kelimenin etiketi farklı olduğunda atanır.

I-[UPOS] (Inside): Aynı sözcük türünden ardışık kelimelerin devam ettiğini gösterir (Örn: Peş peşe gelen isim tamlamaları veya birleşik yapılar).

5.2. CoNLL-U Çıktı Örneği

Model tarafından üretilen output/predictions_test.conllu dosyasından alınan örnek bir cümle ve tahmin çıktısı aşağıdaki gibidir:

conllu

sent_id = boun_test_001

text = Kitabı çok beğendim.

1 Kitabı kitap NOUN _ Case=Acc 2 obj _ PredBIO=B-NOUN

2 çok çok ADV _ _ 3 advmod _ PredBIO=B-ADV

3 beğendim beğen VERB _ Tense=Past 0 root _ PredBIO=B-VERB

4 . . PUNCT _ _ 3 punct _ PredBIO=B-PUNCT

Yukarıdaki örnekte görüldüğü üzere, modelin her bir token için tahmin ettiği UPOS etiketleri cümlelerin orijinal yapısını bozmadan MISC sütununa PredBIO=B-[UPOS] veya PredBIO=I-[UPOS] formatında başarıyla eklenmiştir.

6. PROJE DEĞERLENDİRMESİ VE GELECEK ÇALIŞMALAR

6.1. Güçlü Yönler

Hızlı ve Etkin Çalışma Süresi: Multinomial Logistic Regression algoritması seyrek matrisler üzerinde son derece optimize çalışmaktadır. Tüm eğitim süreci sadece 12.9 saniyede tamamlanmaktadır. Bu durum, modelin hiper-parametre ayarlarının hızlıca test edilmesine imkan tanımıştır.

Kapsamlı Sonek Analizleri: Türkçe eklerini yakalamak üzere tasarlanan suffix_1 ila suffix_5 özellikleri sayesinde kelimelerin çekim durumları ve yapım ekleri yüksek doğrulukla sınıflandırılmıştır.

Bağlam Duyarlılığı: Sağ ve sol bağlamsal pencerelerin dahil edilmesi, kelimenin sadece kendi biçimine değil cümle içindeki konumuna göre karar verilmesini sağlayarak morfolojik belirsizliklerin büyük oranda giderilmesini sağlamıştır.

6.2. Zayıf Yönler ve Geliştirme Önerileri

Veri Dengesizliği (Data Imbalance): INTJ (Ünlem) ve SCONJ (Bağlaç) gibi seyrek sınıfların performansı düşüktür. Gelecekte sentetik veri artırma (oversampling) veya sınıf ağırlıklandırma (class weights) yöntemleri modele entegre edilerek bu sınıfların başarımlarını artırılabilir.

Derin Öğrenme Entegrasyonu: Lojistik Regresyon doğrusal sınırlarla çalışmaktadır. Daha karmaşık bağlamsal ilişkileri yakalamak amacıyla derin öğrenme tabanlı dizi etiketleme modelleri (Bi-LSTM, CRF veya Türkçe BERT/ELECTRA modelleri) kullanılarak başarımların %92.23 seviyesinden daha yukarıya taşınabilir.

7. SONUÇ

Bu projede, Türkçe morfolojik çözümleme ve UPOS etiketleme görevi istatistiksel makine öğrenmesi yaklaşımları çerçevesinde başarıyla tamamlanmıştır. Geliştirilen Multinomial Logistic Regression modeli, %92.23 doğruluk ve %84.82 Macro F1 skoru elde ederek Türkçe gibi morfolojik açıdan zorlu ve eklemeli bir dil üzerinde kabul edilebilir akademik standartlarda bir başarımlar seviyesine ulaşmıştır.

Proje kapsamında talep edilen tüm isterler (istatistiksel model kullanımı, CoNLL BIO işaretleme, çalışır eğitim/test kodu ve grafik tabanlı metrik raporlamaları) eksiksiz olarak yerine getirilmiştir. Geliştirilen modüller kod yapısı, ilerleyen süreçte yeni özelliklerin ve algoritmaların test edilmesine de olanak tanıyacak esnekliktedir.